HMAE 异构多智能体医疗 AI 生态系统
底层数学与物理逻辑推导
——附公理体系推演

MAPFM Medical AI Research Framework

Heterogeneous Multi-Agent Ecosystem v2.0

丰富讲解版（含公理化推导）

2026 年 5 月 29 日

摘要本文从第一性原理出发，系统推导 HMAE 异构多智能体医疗 AI 生态系统的完整数学与物理基础。全文分为五个部分：(I) 十大智能体的核心数学公式与物理类比；(II) 支撑基础设施的数学推导；(III) 跨模块耦合与系统动力学；(IV) 输出评价体系；(V) 从数学结构中提炼的公理体系。第五部分是本文的核心创新——我们从工程实现中逆向归纳出 8 条公理，构成本系统的公理化基础。

目录

第一部分　智能体部分——Agent Mathematical Foundations **6**

1　感知智能体 (Perception Agent) **6**
- 1.1　设计动机与物理直觉 6
- 1.2　文本编码 6
- 1.3　图像编码 (ViT Patching) 6
- 1.4　交叉注意力融合 (Cross-Attention Fusion) 7

2　检索增强智能体 (RAA —Retrieval-Augmented Agent) **7**
- 2.1　双通道检索的互补性原理 7
- 2.2　稀疏检索：TF-IDF 余弦相似度 8
- 2.3　稠密检索：FAISS 内积搜索 8
- 2.4　查询不确定性量化 8
- 2.5　重排序 (Rerank-RAG) 9

3　决策智能体 (DMA —Decision-Making Agent) **9**
- 3.1　决策理论的几何解释 9
- 3.2　基于质心的 TF-IDF 分类 9

3.3 多源得分融合 . . . 10
3.4 易混淆疾病消歧 . . . 10
3.5 Softmax 概率输出 . . . 10
3.6 Platt 置信度校准 . . . 11
3.7 Llama3:8b 推理（主路径） . . . 11

4 时序预见智能体 (TFA —Temporal Foreseeing Agent) 11
4.1 时间序列预测的物理框架 . . . 11
4.2 多尺度时序特征抽取 . . . 11
4.3 门控融合 . . . 12
4.4 多窗口风险预测 . . . 12
4.5 DMA 置信度校准 . . . 13
4.6 MedTsLLM-v1.5 路径（真实推理） . . . 14
4.7 风险等级分类 . . . 14

5 知识融合智能体 (Fusion Agent) 14
5.1 SimHash 指纹与去重 . . . 14
5.1.1 SimHash 的数学原理 . . . 14
5.2 冲突检测 . . . 15
5.3 区域共识得分 . . . 15

6 验证智能体 (Verification Agent) 16
6.1 事实核对评分 . . . 16
6.2 时效性检查 . . . 16
6.3 TFA 报告验证 . . . 16

7 隐私智能体 (Privacy Agent) 16
7.1 差分隐私的数学基础 . . . 16
7.2 联邦梯度扰动 . . . 17
7.3 XOR 流加密 . . . 17

8 维护智能体 (Maintenance Agent) 17
8.1 心跳监测 . . . 17
8.2 异常输出检测 . . . 18

9 通信拓扑智能体 (Topology Manager) 18
9.1 网络模型 . . . 18
9.2 路由路径 . . . 18
9.3 消息重试队列 . . . 18

10 共识智能体 (Consensus Module) **19**
10.1 投票权重分配 19
10.2 三层级协同决策 19

11 纳什均衡检索策略选择 **20**
11.1 博弈论框架 20
11.2 最佳反应迭代 20
11.3 收敛条件 20

第二部分 其他部分——Supporting Modules & Infrastructure **21**

12 动态知识库 (Online Knowledge Base) **21**
12.1 增量知识更新 21
12.2 文档权重反馈更新 21
12.3 FAISS 索引重建 21

13 三源知识融合 (Tri-Source Fusion) **22**
13.1 信源加权融合 22

14 知识蒸馏引擎 (Knowledge Distillation) **22**
14.1 加权平均上下文向量 22

15 人在回路管理 (HITL Manager) **22**
15.1 三层干预架构 22
15.2 TFA 特异性 HITL 23
15.3 错误分类与诊断 23

16 模拟 LoRA 微调 (Simulated LoRA Fine-Tuner) **23**
16.1 隐私感知梯度聚合 23
16.2 校准因子更新 23
16.3 类比偏差累积 24

17 对比检索更新 (Contrastive Retrieval Updater) **24**
17.1 检索裕度偏移 24

18 退化管理 (Degradation Manager) **24**
18.1 三级退化机制 24

19 持续学习循环 (Continuous Learning Loop) **25**
19.1 触发条件与周期执行 25

20 MedTsLLM-v1.5 适配器 **25**
20.1 BioBERT 冻结骨干 . . . 25
20.2 时间序列 → 语言空间重编程 . . . 25
20.3 输出投影与风险解耦 . . . 26

第三部分 相互联系——Inter-Module Coupling & System Dynamics **26**

21 端到端流水线数据流 **26**

22 耦合矩阵——跨模块信息依赖 **27**

23 通信拓扑：星型网络上的信息传播 **27**

24 系统整体平衡方程 **27**

25 物理类比总结 **28**

第四部分 输出结果分析——Output Analysis & Evaluation Framework **29**

26 评价指标体系 **29**
26.1 分类指标 . . . 29
26.2 消融实验指标 . . . 29
26.3 噪声鲁棒性指标 . . . 29
26.4 数据规模适应性指标 . . . 29
26.5 常见/罕见病差异指标 . . . 30

27 系统级输出分析 **30**
27.1 TFA 风险预测输出结构 . . . 30
27.2 共识决策输出结构 . . . 30
27.3 系统综合答案 (Comprehensive Answer) . . . 30

28 消融实验分析框架 **30**

29 持续学习收敛分析 **31**

30 退化水平对输出的影响 **31**

31 系统全面报告 (Full Report) **31**

第五部分 公理体系推演——Axiomatic Foundations of HMAE **31**

32 从工程实现到公理体系的逆向归纳 **32**
32.1 为什么需要公理化 32
32.2 归纳方法论 32

33 八大公理 **32**

34 从公理到定理 **35**
34.1 公理体系的完备性与独立性 35
34.2 可推导的核心定理 35

35 公理体系在非医疗领域的可迁移性 **36**

36 公理体系的方法论意义：从” 工程直觉” 到” 形式化保证” **36**

附录 **37**

第一部分 智能体部分——Agent Mathematical Foundations

Part I 涵盖 HMAE 生态系统的十大核心智能体。每个智能体的数学推导都对应一个物理系统的类比，这一”数学-物理”双重对应关系是理解整个系统行为的关键。

1 感知智能体 (Perception Agent)

1.1 设计动机与物理直觉

感知智能体是多模态输入的” 统一入口”。它的核心任务是将异质的临床数据（文本、图像）映射到一个共同的低维语义流形 $\mathcal{M} \subset \mathbb{S}^{d-1}$（单位超球面）上。这一映射在物理上等价于**降维投影测量（dimensionality-reducing projective measurement）**：我们从一个极高维的原始信号空间（文本 token 空间 $\sim 10^4$ 维 + 图像像素空间 $\sim 10^5$ 维）投影到 $d = 128$ 维的语义流形，保留下游任务最需要的信息分量。

1.2 文本编码

输入临床文本 X_{txt} 首先通过 MiniLM (all-MiniLM-L6-v2) 编码器映射为语义向量：

$$\mathbf{v}_{\text{txt}} = \text{MiniLM}(X_{\text{txt}}) \in \mathbb{R}^{d_{\text{MiniLM}}} \tag{1}$$

其中 $d_{\text{MiniLM}} = 384$（MiniLM 原生维度），随后通过分块均值降维至项目维度 $d = 128$：

$$\mathbf{v}_{\text{txt}}^{(d)} = \text{Resize}(\mathbf{v}_{\text{txt}}, d) = \text{L2}\left(\left[\text{mean}(\mathbf{v}_{\text{chunk}_k})\right]_{k=1}^{d}\right) \tag{2}$$

物理注解： L2 归一化将所有向量约束在单位球面 S^{d-1} 上。这一约束的深层含义是：在语义空间中，**方向比幅值更重要**。两个临床文本的相似度仅由它们之间的夹角决定，文本长度（信息量大小）不影响语义比较。这在物理上对应量子态的描述——态的物理内容由归一化后的态矢量方向完全确定，模长不承载物理信息。

1.3 图像编码 (ViT Patching)

对输入图像 X_{img}，采用 ViT 风格分块编码：

$$\mathbf{P} = [\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3, \mathbf{p}_4]^\top \in \mathbb{R}^{4\times d} \tag{3}$$

其中每个 $\mathbf{p}_i$ 来自图像块的文本代理编码：$\mathbf{p}_i = \text{MiniLM}\left(\text{TextProxy}(\text{flatten}(X_{\text{img}})_{[i\cdot s:(i+1)\cdot s]})\right)$。图像上下文向量：

$$\mathbf{v}_{\text{img}} = \text{L2}\left(\frac{1}{4}\sum_{i=1}^{4}\mathbf{p}_i\right) \tag{4}$$

设计原理： 使用 TextProxy 将图像像素映射为文本描述再通过 MiniLM 编码，这一” 迂回” 策略的深层原因是——MiniLM 是在自然语言语料上预训练的，直接输入像素值会产生

分布外 (out-of-distribution) 激活。TextProxy 将像素统计量翻译为自然语言描述（如"region 1: high intensity, irregular texture"），使图像信息进入 MiniLM 的分布内区域，从而获得有意义的语义编码。这在物理上等价于**量子测量中的经典仪器读数**：量子系统（图像）的信息必须通过经典仪器（TextProxy）转换为经典语言才能被经典处理器（MiniLM）理解。

1.4 交叉注意力融合 (Cross-Attention Fusion)

融合层通过文本向量 $\mathbf{q} = \mathbf{v}_{\text{txt}}$（作为查询）与图像块 $\mathbf{P}$ 进行注意力计算：

$$\mathbf{a} = \text{softmax}\left(\frac{\mathbf{P}\,\mathbf{q}^\top}{\sqrt{d}}\right) \in \mathbb{R}^4 \tag{5}$$

视觉上下文：

$$\mathbf{c}_{\text{vis}} = \sum_{i=1}^{4} a_i \cdot \mathbf{p}_i \tag{6}$$

最终融合上下文向量通过串联 + 线性投影：

$$\mathbf{v}_{\text{fused}} = \text{L2}\left(\left[\mathbf{v}_{\text{txt}} \quad \mathbf{c}_{\text{vis}}\right] \cdot \mathbf{W}_{\text{fusion}}\right) \tag{7}$$

其中 $\mathbf{W}_{\text{fusion}} \in \mathbb{R}^{2d\times d}$，初始化 $w_{ij} \sim \mathcal{N}(0, 1/\sqrt{d})$。

注 1.1 (交叉注意力的物理意义). 式 (7) 的物理意义极为深刻：文本语义与视觉信号在高维流形上的交集投影。**当图像与文本描述一致时**（如文本描述" 肺部 X 光显示右下叶浸润"，图像确实显示该特征），注意力权重 a_i 会高度集中在包含该特征的图像块上，使得 $\mathbf{c}_{\text{vis}}$ 与 $\mathbf{v}_{\text{txt}}$ 方向对齐。此时 $\mathbf{v}_{\text{fused}}$ 的范数接近 1，表示" 高置信度融合"。

当图文不一致时（如文本描述肺炎但图像显示正常肺），注意力权重分散，$\mathbf{c}_{\text{vis}}$ 与 $\mathbf{v}_{\text{txt}}$ 方向偏离。L2 约束使融合向量仍位于单位球面上，但其方向偏离了文本与图像的共同方向，系统通过向量夹角的增大自然地表达了" 不确定性"。

这一机制在数学上等价于**量子纠缠态的投影测量**：两个子系统（文本、图像）的联合态被投影到一个共同的本征基上，融合结果取决于两个子系统是否" 相容"（即是否处于同一本征态）。

2 检索增强智能体 (RAA —Retrieval-Augmented Agent)

2.1 双通道检索的互补性原理

RAA 同时运行稀疏检索（TF-IDF）和稠密检索（FAISS）两个通道。这并非工程上的冗余设计，而是基于深刻的**信号处理对偶性**：

- **稀疏检索（词频空间）**：在词项的离散基上操作，擅长精确词匹配，等价于信号处理中的**时域分析**——定位到具体的关键词。
- **稠密检索（语义空间）**：在连续嵌入基上操作，擅长语义近似匹配，等价于信号处理中的**频域分析**——捕获整体的语义" 频谱"。

二者的融合可以用 **Gabor 变换的离散类比**来理解：TF-IDF 提供了" 哪个词在哪里出现" 的局部信息，FAISS 提供了" 整体语义是什么" 的全局信息。同时使用两者，类似于在时频平面上同时具有最优分辨率（虽然受制于不确定性原理的 trade-off，见第五部分公理 2）。

2.2 稀疏检索：TF-IDF 余弦相似度

给定查询 q 和文档集 $\mathcal{D}$，构建 TF-IDF 矩阵 $\mathbf{M} \in \mathbb{R}^{|\mathcal{D}| \times k_{\max}}$（$k_{\max} = 2400$）：

$$w_{ij} = \mathrm{tf}(t_j, d_i) \cdot \log \frac{|\mathcal{D}|}{|\{d \in \mathcal{D} : t_j \in d\}|} \tag{8}$$

采用次线性 TF 缩放 $\mathrm{tf}_{\mathrm{sub}}(t,d) = 1 + \log(1 + \log(\mathrm{tf}(t,d)))$ 和 $(1,3)$-gram 范围。

次线性缩放的物理原因：一个词在文档中出现 100 次并不比出现 10 次传递 10 倍的信息量。次线性缩放符合**信息论中的递减边际信息原理**——每增加一次出现的边际信息增益随出现次数递减。双重对数 $1+\log(1+\log(\cdot))$ 确保了即使对于极高频词，权重增长也被严格压制。

查询向量 $\mathbf{q}_{\mathrm{tfidf}} = \mathrm{Vectorizer}(q)$，相似度：

$$s_{\mathrm{sparse}}(d_i) = \cos(\mathbf{q}_{\mathrm{tfidf}}, \mathbf{m}_i) = \frac{\mathbf{q}_{\mathrm{tfidf}} \cdot \mathbf{m}_i}{\|\mathbf{q}_{\mathrm{tfidf}}\|_2 \cdot \|\mathbf{m}_i\|_2} \tag{9}$$

加权相似度：$s'_{\mathrm{sparse}}(d_i) = s_{\mathrm{sparse}}(d_i) \cdot w_{\mathrm{doc}}(d_i)$，其中 $w_{\mathrm{doc}}(d_i)$ 为文档动态权重。

2.3 稠密检索：FAISS 内积搜索

语义向量通过 MiniLM 编码后经 FAISS 索引（IndexFlatIP）进行最大内积搜索（MIPS）：

$$\mathbf{e}_q = \mathrm{MiniLM}(q) \in \mathbb{R}^d, \quad \mathbf{M}_{\mathrm{dense}} \in \mathbb{R}^{|\mathcal{D}| \times d} \tag{10}$$

$$s_{\mathrm{dense}}(d_i) = \frac{\langle \mathbf{e}_q, \mathbf{m}_i^{\mathrm{dense}} \rangle + 1}{2} \in [0,1] \tag{11}$$

注 2.1 (内积搜索的几何本质). 在 L2 归一化后（即所有向量在单位球面上），内积 $\langle \mathbf{a}, \mathbf{b} \rangle$ 严格等于 $\cos(\theta_{\mathbf{a},\mathbf{b}})$。因此 FAISS MIPS 实际上是在球面上寻找与查询向量夹角最小的文档——等价于球面上的最近邻搜索。归一化至 $[0,1]$ 区间的变换 $(\cos\theta + 1)/2$ 将角度 $[0,\pi]$ 线性映射到 $[0,1]$，保持了顺序关系（单调递减映射的逆）。

2.4 查询不确定性量化

RAA 通过三组分解合不确定性估计查询难度：

$$H(P) = -\sum_{i=1}^{5} p_i \log p_i / \log(5) \quad \text{(归一化熵)} \tag{12}$$

$$G(P) = 1 - \mathrm{clip}_{[0,1]}(p_1 - p_2) \quad \text{(Top-2 间隙)} \tag{13}$$

$$O(q) = \mathbb{I}[|\mathrm{tokens}(q)| \le 2] \quad \text{(OOV 代理)} \tag{14}$$

$$U(q) = \alpha_H \cdot H(P) + \alpha_G \cdot G(P) + \alpha_O \cdot O(q) \tag{15}$$

其中 $\alpha_H = 0.58$, $\alpha_G = 0.32$, $\alpha_O = 0.10$，概率 $P = \mathrm{softmax}(\mathbf{s}, T = 0.35)$ 来自前 5 个检索结果的相似度得分。

当 $U(q) > \tau_U = 0.58$ 时触发深层检索（扩大 k 至 10 + 多样化策略）。

注 2.2 (不确定性量化的三重分解). $H(P)$（归一化熵）度量检索得分分布的" 平坦度"——如果前 5 个文档得分几乎相同（高熵），说明检索系统无法区分它们，查询本身缺乏区分性信息。这对应**热力学中的最大熵状态**。

$G(P)$（Top-2 间隙）度量最佳文档与次佳文档之间的分离度——如果间隙很小，系统在" 两个都很像" 的歧义状态中。这对应**量子力学中的近简并能级**。

$O(q)$（OOV 代理）标记极短查询（≤ 2 tokens），这种查询几乎一定是 OOV (out-of-vocabulary) 或信息不足的。这对应**信号处理中的欠采样**。

2.5 重排序 (Rerank-RAG)

$$s_{\text{rerank}}(d) = \omega_s \cdot s(d) + \omega_o \cdot \frac{|\mathcal{T}_q \cap \mathcal{T}_d|}{|\mathcal{T}_q|} + \omega_r \cdot e^{-\Delta t/540} + b_{\text{auth}} + b_{\text{med}} \tag{16}$$

其中 $\omega_s = 0.62$, $\omega_o = 0.22$, $\omega_r = 0.10$, $b_{\text{auth}} = 0.10$, $b_{\text{med}} \in [0, 0.12]$。$\Delta t$ 以天为单位，540 天对应约 1.5 年，时效性半衰期约为 $540 \cdot \ln 2 \approx 374$ 天。

注 2.3 (信息检索的哈密顿量类比). 式 (16) 可视为信息检索中的**哈密顿量**（总能量函数）：

- ω_s 项为**势能**（语义匹配——系统的" 位置" 在语义空间中的稳定程度）
- ω_o 项为**动能**（词项交叠——系统的" 运动"，即查询与文档之间的信息流动）
- ω_r 项为**耗散**（信息时效性衰减——热力学第二定律在信息空间中的表达：信息随时间熵增）
- b_{auth} 为**外场偏置**（外部权威源施加的" 磁场"，使检索偏好可信来源）

这一类比不仅仅是比喻：如果我们定义检索空间上的作用量 $S = \int (T - V)dt$，最小作用量原理自然导致最优检索排序。

3 决策智能体 (DMA —Decision-Making Agent)

3.1 决策理论的几何解释

DMA 是整个生态系统的核心。从决策理论的视角，DMA 实现了一个**贝叶斯决策规则**在多源证据下的具体实例化。每个证据源（质心相似度、检索得分、词汇匹配、上下文信号、时序风险）构成一个似然函数 $P(\text{evidence}_k \mid c)$，DMA 的融合得分 s_c^{raw} 恰好是这些对数似然的加权和（在 softmax 归一化之前）。

3.2 基于质心的 TF-IDF 分类

训练阶段，对每类 $c \in \mathcal{C}$ 计算质心：

$$\mathbf{c}_c = \text{L2}\left(\frac{1}{|\mathcal{D}_c|} \sum_{d \in \mathcal{D}_c} \text{TF-IDF}(d) \right) \in \mathbb{R}^{k_{\max}} \tag{17}$$

推理阶段，查询 q 对各质心的相似度：

$$s_c^{\text{centroid}}(q) = \langle \text{L2}(\text{TF-IDF}(q)), \mathbf{c}_c \rangle \tag{18}$$

几何解释：每个疾病类在 TF-IDF 空间中由一个单位向量（质心）代表。分类过程等价于在 $k_{\max}$ 维单位球面上寻找与查询向量夹角最小的质心。这构成一个 **Voronoi 划分**——决策边界由相邻质心的中垂超平面确定。

3.3 多源得分融合

DMA 的原始得分由五部分组成：

$$s_c^{\text{raw}} = \underbrace{\lambda_c s_c^{\text{centroid}}}_{\text{质心}} + \underbrace{\lambda_r s_c^{\text{retrieval}}}_{\text{检索}} + \underbrace{\lambda_l s_c^{\text{lexical}}}_{\text{词汇}} + \underbrace{\lambda_k \cdot (1 - H(\mathbf{a}))}_{\text{上下文}} + \underbrace{\lambda_t \cdot r_{\text{TFA}}}_{\text{时序风险}} + b_c \tag{19}$$

其中权重系数：$\lambda_c = 0.50$, $\lambda_r = 0.34$, $\lambda_l = 0.12$, $\lambda_k = 0.02$, $\lambda_t = 0.02$。$H(\mathbf{a}) = -\sum_i a_i \log a_i$ 为交叉注意力权重向量 $\mathbf{a}$（式 5）的熵，该项反映图文融合质量——当图文一致时注意力集中（H 低，$1 - H$ 高），不一致时注意力分散（H 高，$1 - H$ 低）。

注 3.1 (权重分配的信息论解释). 权重 $\boldsymbol{\lambda} = [0.50, 0.34, 0.12, 0.02, 0.02]$ 并非随意设定。它们近似满足**信息衰减的幂律**：质心（最可靠的结构化知识）占主导权重 0.50；检索（外部证据）次之，占 0.34；词汇（表面匹配）再次之，占 0.12。这种分配在数学上近似于以 $r \approx 0.68$ 为公比的几何级数衰减，反映了从" 结构化先验" 到" 弱信号" 的信息可靠性递减链。

检索得分归一化：$s_c^{\text{retrieval}} = \sum_{d:\text{area}(d)=c} s(d) \cdot w_{\text{doc}}(d) / \sum_d s(d) \cdot w_{\text{doc}}(d)$。
词汇先验：$s_c^{\text{lexical}} = |\mathcal{T}_q \cap \mathcal{T}_c| / \max(|\mathcal{T}_c|, 1)$。

3.4 易混淆疾病消歧

对于查询标记与疾病标签的直接匹配、同义词匹配和部分重叠，应用离散奖励：

$$s_c^{\text{raw}} \leftarrow s_c^{\text{raw}} + \begin{cases} 4.0 & \text{if } \mathcal{T}_c \subseteq \mathcal{T}_q \text{ or } |\text{Syn}(\mathcal{T}_c) \cap \mathcal{T}_q| \geq 2 \\ 2.0 & \text{if } |\text{Syn}(\mathcal{T}_c) \cap \mathcal{T}_q| \geq 1 \\ 2.0 & \text{if } |\mathcal{T}_c \cap \mathcal{T}_q| \geq 0.5 \cdot |\mathcal{T}_c| \end{cases} \tag{20}$$

离散奖励的博弈论解释：这不是连续得分，而是一种**信号机制（signaling）**——当查询中的词汇与某疾病的术语集中的词精确匹配（特别是同义词匹配）时，这传递了一个几乎无噪声的" 信号"，远远强于统计相似度。+4.0 的加成相当于统计得分在因子 $\sim 1.5\times$ 级别上的偏移，确保精确术语匹配在决策中产生决定性影响。

3.5 Softmax 概率输出

$$P(c|q) = \frac{\exp(s_c^{\text{raw}}/T)}{\sum_{c'} \exp(s_{c'}^{\text{raw}}/T)}, \quad T = 0.18 \tag{21}$$

注 3.2 (低温极限的物理意义). 低温 $T = 0.18$ 使 softmax 趋近于 argmax（低熵分布）。在统计力学中，温度 $T \to 0$ 时系统冻结至基态——所有概率质量集中在最低能量状态。在 DMA 中，低温度确保系统输出的概率分布高度尖锐（低熵），
当 $T \to 0$ 时： $\text{softmax}(\mathbf{s}/T) \to \text{one_hot}(\arg\max \mathbf{s})$，系统退化为确定性分类器。

当 $T \to \infty$ 时： $\text{softmax}(\mathbf{s}/T) \to \text{uniform}$，系统退化为随机猜测。
物理上，$T = 0.18$ 在" 尖锐决策" 和" 保留不确定性度量" 之间取得平衡——系统有足够的置信度进行决策，同时保留了概率排序信息用于后续校准。

3.6 Platt 置信度校准

原始置信度 $\bar{p} = \max_c P(c|q)$ 经 Platt scaling 校准：

$$p_{\text{cal}} = \frac{1}{1 + \exp(-(A \cdot \bar{p} + B))} \tag{22}$$

其中 (A, B) 通过 SGD 在滑动窗口（最近 200 对 $(\bar{p}, \text{is_correct})$）上拟合逻辑回归得到：

$$a \leftarrow a - \eta \cdot \mathbb{E}[(p_{\text{cal}} - y) \cdot \bar{p}], \quad b \leftarrow b - \eta \cdot \mathbb{E}[p_{\text{cal}} - y] \tag{23}$$

注 3.3 (Platt 校准与最大熵原理). Platt scaling 本质上是在**保序变换**的约束下，寻找使预测置信度与实际正确率最一致的单调映射。这等价于在保持 ROC 曲线不变的条件下，最小化预测分布与经验分布之间的 KL 散度。从统计力学的角度看，这是受保序约束的最大熵校准——最终的校准曲线是玻尔兹曼分布的一维投影。

3.7 Llama3:8b 推理（主路径）

当 Ollama 服务可用时，DMA 通过 LLAMA3_PROMPT_TEMPLATE 构造提示词，调用本地 Llama3:8b 结构化 JSON 推理。Ollama 失败时自动回退至上述质心 + 检索融合路径。

双路径架构的深层逻辑： Llama3 路径提供" 深度推理"（链式思维、综合判断），质心路径提供" 快速模式匹配"（统计相似度）。这对应人类诊断的双过程理论 (dual-process theory)：

- System 1（质心路径）：快速、直觉、基于模式识别（对应 Kahneman 的" 快思考"）
- System 2（Llama3 路径）：缓慢、分析、基于逻辑推理（对应 Kahneman 的" 慢思考"）

4 时序预见智能体 (TFA —Temporal Foreseeing Agent)

4.1 时间序列预测的物理框架

TFA 实现了一个**物理信息系统中的状态预测器**。其核心思想是：将临床时间序列视为一个受噪声扰动的动力系统的观测轨迹，目标是推断系统的隐藏状态并预测未来演化。

4.2 多尺度时序特征抽取

TFA 从 72 点历史时间序列 $x_{1:T}$（$T = 72$）中提取三类特征：
TCN（时序卷积网络代理特征）：

$$f_{\text{TCN}} = \frac{1}{|W|} \sum_{t \in W} \Delta x_t + 0.30 \cdot \sigma_W, \quad \Delta x_t = x_t - x_{t-1}, \quad W = x_{T-23:T} \tag{24}$$

EMA（指数加权移动平均代理特征）：

$$h_t = \alpha \cdot x_t + (1-\alpha) \cdot h_{t-1}, \quad \alpha = 0.18 \tag{25}$$

$$f_{\text{EMA}} = h_T \tag{26}$$

Transformer（自注意力代理特征）：

$$f_{\text{Trans}} = \sum_{t=1}^{T} x_t \cdot \frac{\exp((\text{pos}_t + 0.2 \cdot x_t)/0.45)}{\sum_j \exp((\text{pos}_j + 0.2 \cdot x_j)/0.45)} \tag{27}$$

其中 $\text{pos}_t = t/T \in [0,1]$。

注 4.1 (三种特征的时间尺度对应). 三类特征对应于三个物理时间尺度上的信息提取：

- **TCN（短期，$W = 24$ 窗口）**：局部梯度——最近的趋势和波动。等价于动力系统的**局部导数**估计（相空间中的速度）。
- **EMA（全程，指数衰减记忆 $\alpha = 0.18$，半衰期约 3.8 步）**：长期累积——整个历史的指数加权平均。等价于动力系统的**李雅普诺夫函数**（系统能量的单调趋势）。
- **Transformer（全局，位置编码加权）**：全局注意力——所有时间点的位置加权融合。等价于**路径积分**——每一条历史路径根据其" 重要性"（位置 + 信号强度）贡献于当前状态估计。

$\alpha = 0.18$ 的半衰期为 $\ln(0.5)/\ln(0.82) \approx 3.8$ 个时间步——意味着大约每 4 个时间步，历史信息的影响衰减一半。

4.3 门控融合

$$g_k = \frac{\exp(|f_k|/T_g)}{\sum_j \exp(|f_j|/T_g)}, \quad T_g = 0.35 \tag{28}$$

$$f_{\text{fused}} = g_1 \cdot f_{\text{TCN}} + g_2 \cdot f_{\text{EMA}} + g_3 \cdot f_{\text{Trans}} \tag{29}$$

门控融合的量子测量类比：门控权重 g_k 基于特征的**幅值**（而非方向）分配——信号越强的特征获得越大的权重。这类似于量子测量中的 **波恩规则（Born rule）**：测量得到某结果的概率正比于对应本征态的概率幅的模方。$T_g = 0.35$ 控制了门控的" 选择性"——低温使门控更尖锐（赢家通吃），高温使门控更均匀（平均融合）。

4.4 多窗口风险预测

其中：

- $r_{\text{base}} \in [0,1]$ —TFA 基础预测模型输出的原始风险得分
- $\delta_{\text{fall}} \in \{0, 0.15\}$ —跌倒事件指示量，0 表示无跌倒，0.15 表示有跌倒事件发生
- $r_p = 0.08$ —压疮增长率常数，控制压疮风险随卧床时间增长的速率
- $f_{\text{fall}} = \omega_p \cdot p_{\text{inst}} + \omega_a \cdot (1 - a_{\text{level}})$ —跌倒特征，其中 $\omega_p = 0.6$, $\omega_a = 0.4$

$$r_{\text{short}} = \sigma\left(f_{\text{fused}} + b_{\text{auth}} + f_{\text{fall}} + \delta_{\text{fall}}\right) \cdot \mu_{\text{acute}} \tag{30}$$

$$r_{\text{mid}} = \text{clip}\left(0.72 \cdot r_{\text{base}} + 0.28 \cdot \sigma\left(\frac{1}{T}\sum_{t} x_t\right) + 0.5 \cdot f_{\text{fall}}\right) \tag{31}$$

$$r_{\text{long}} = \text{clip}\left(\left(0.58 \cdot r_{\text{base}} + 0.42 \cdot \sigma\left(\frac{1}{36}\sum_{t=T-35}^{T} x_t\right)\right) \cdot \mu_{\text{chronic}} + g_{\text{pressure}}\right) \tag{32}$$

其中：

- $\sigma(z) = 1/(1+e^{-z})$ —逻辑函数（物理中的费米-狄拉克分布）
- $\mu_{\text{acute}} \in \{1.0, 3.0\}$ —急性病程乘数
- $\mu_{\text{chronic}} \in \{1.0, 2.0\}$ —慢性病程乘数
- $g_{\text{pressure}} = 1 - e^{-r_p \cdot h_{\text{bed}}}$ —压疮增长模型（指数衰减补）
- $f_{\text{fall}} = \omega_p \cdot p_{\text{inst}} + \omega_a \cdot (1 - a_{\text{level}})$ —跌倒特征

注 4.2 (多窗口预测的多尺度物理类比). 三个时间窗口对应临床中的三个风险时间尺度：

- **短期 (24h)**：受急性因子（感染、跌倒）主导，$\mu_{\text{acute}} \in \{1, 3\}$ 在急性病存在时将风险乘以 3 倍
- **中期 (30d)**：短期趋势与长期基线以 0.72 : 0.28 的比例混合——权重反映了" 近期信息比远期信息更相关" 的指数衰减先验
- **长期 (12m)**：受慢性因子主导，基线权重更高 (0.58)，且引入了压疮增长的指数饱和模型 $g_{\text{pressure}} = 1 - e^{-r_p h_{\text{bed}}}$——卧床时间越长，压疮风险以递减速率增加（边际效应递减）

逻辑函数 $\sigma(z)$ 在物理中描述费米子在各能级上的占据概率；在风险预测中，它提供了一种将无界实数信号映射到 $[0, 1]$ 概率的自然方式。

4.5 DMA 置信度校准

TFA 根据 DMA 置信度 γ_{DMA} 调整自身预测：

$$r' = r \cdot \begin{cases} 1.0 & \text{if } \gamma_{\text{DMA}} \geq 0.9 \\ 0.9 & \text{if } 0.7 \leq \gamma_{\text{DMA}} < 0.9 \\ 0.8 & \text{if } 0.6 \leq \gamma_{\text{DMA}} < 0.7 \\ 1.0 \text{ (degraded)} & \text{if } \gamma_{\text{DMA}} < 0.6 \end{cases} \tag{33}$$

校准策略的贝叶斯解释：当 DMA 置信度极高 (≥ 0.9) 时，诊断已经非常确定，TFA 不需要调整风险预测（诊断信息已经充分）。当 DMA 置信度中等 (0.6–0.9) 时，诊断的不确定性传递到风险预测——乘数 < 1 反映了" 如果我们不确定诊断，那么基于该诊断的风险预测也应该更保守"。当 DMA 置信度极低 (< 0.6) 时，乘数恢复为 1.0 但标记 degraded——这意味着 DMA 的置信度太低以至于不可靠，TFA 不应根据不可靠的信息调整自身预测（不传递虚假的降低信号）。

4.6 MedTsLLM-v1.5 路径（真实推理）

当 MedTsLLM 可用时，TFA 切换到基于 BioBERT 的深度推理：

时间序列标准化 (RevIN):

$$\tilde{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad \mu_B = \frac{1}{T}\sum x_t, \quad \sigma_B^2 = \frac{1}{T}\sum (x_t - \mu_B)^2 \tag{34}$$

分块嵌入 (Patch Embedding):

$$\mathbf{P}_{\text{patch}} = \text{Conv1D}(\text{Unfold}(\tilde{x})), \quad \text{patch_len} = 12, \text{stride} = 6 \tag{35}$$

重编程层 (Reprogramming Layer) —交叉注意力：

$$\mathbf{Q} = \mathbf{P}_{\text{patch}}\mathbf{W}_Q \in \mathbb{R}^{B\times L\times H\times E}, \quad \mathbf{K} = \mathbf{E}_{\text{word}}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{E}_{\text{word}}\mathbf{W}_V \tag{36}$$

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{E}}\right)\mathbf{V} \tag{37}$$

其中 $\mathbf{E}_{\text{word}}$ 是 BioBERT 的冻结词嵌入，重编程层将时序分块信号" 翻译" 为大语言模型可理解的语义空间。

BioBERT 编码 + FlattenHead:

$$\mathbf{h} = \text{BioBERT}\left([\text{PromptEmb}, \text{Reprogrammed}]\right)_{\text{last_hidden}} \tag{38}$$

$$\hat{\mathbf{r}} = \sigma\left(\text{FlattenHead}(\mathbf{h}_{[-n_{\text{patches}}:,:d_{\text{ff}}]})\right) \in [0,1]^{3\times 3} \tag{39}$$

4.7 风险等级分类

$$\text{RiskLevel}(r) = \begin{cases} \text{critical} & \max(r_s, r_m, r_l) \geq 0.85 \\ \text{high} & \max(r_s, r_m, r_l) \geq 0.65 \\ \text{medium} & \max(r_s, r_m, r_l) \geq 0.35 \\ \text{low} & \text{otherwise} \end{cases} \tag{40}$$

阈值选择的临床逻辑：四个阈值 $\{0.35, 0.65, 0.85\}$ 将风险概率空间 $[0,1]$ 划分为四个区域，这些间隔并非均匀分布。它们反映了临床决策中的**非对称损失函数：**假阴性（漏诊）的代价远大于假阳性（误报）。因此 medium 阈值 (0.35) 设置得相对较低——即使只有 35% 的风险概率，也值得引起注意（进入 medium 级别）。

5 知识融合智能体 (Fusion Agent)

5.1 SimHash 指纹与去重

5.1.1 SimHash 的数学原理

SimHash 是一种局部敏感哈希 (LSH)，其核心性质是：语义相似的文档产生汉明距离小的哈希码。在数学上，SimHash 将文档从高维词频空间 $\mathbb{R}^V$ 映射到 64 维超立方体 $\mathbb{H}^{64} \cong (\mathbb{Z}_2)^{64}$，并保持角度相似性（内积的符号一致性）。

文档 d_i 的 SimHash 指纹计算：

$$\text{simhash}(d_i) = \sum_{t \in \text{tokens}(d_i)} \sum_{b=0}^{63} \mathbb{I}[\text{bit}_b(\text{MD5}(t)) = 1] \cdot 2^b \tag{41}$$

实际使用加权累加器：

$$\text{Acc}[b] = \sum_t \begin{cases} +1 & \text{if bit}_b(\text{MD5}(t)) = 1 \\ -1 & \text{otherwise} \end{cases} \tag{42}$$

$$\text{simhash}(d_i) = \sum_{b=0}^{63} \mathbb{I}[\text{Acc}[b] \geq 0] \cdot 2^b \tag{43}$$

物理解释：将每个 token 视为超立方体中的随机向量（通过 MD5 哈希的雪崩效应保证均匀分布）。文档的 SimHash 是所有 token 向量的" 多数投票"——在每个维度上，如果多数 token 的比特为 1，则该维度取 1。这使得文档指纹在超立方体中位于其所有 token 指向方向的" 中心区域"。

去重条件（冲突检测的反面）：

$$\text{dup}(d_i, d_j) \iff \text{Hamming}(\text{simhash}(d_i), \text{simhash}(d_j)) \leq \tau_{\text{dup}} = 4 \tag{44}$$

注 5.1 ($\tau_{\text{dup}} = 4$ 的统计含义). 对于均匀随机分布的 64 位哈希码，任意两个哈希码的汉明距离近似服从 $\mathcal{N}(32, 16)$。$\tau_{\text{dup}} = 4$ 意味着我们要求两个文档的哈希码在超立方体中非常接近（距离远小于期望值 32）。在统计上，随机两个文档满足 Hamming ≤ 4 的概率约为 $2^{-64} \cdot \sum_{k=0}^{4} \binom{64}{k} \approx 10^{-12}$，几乎不可能来自偶然——这确保了去重的高精度。

上述概率计算基于均匀随机哈希的理想化假设。实际中 SimHash 的分布可能偏离均匀分布，因此阈值 $\tau_{\text{dup}} = 4$ 需要在具体知识库上通过实验验证去重精度。

5.2 冲突检测

$$\text{conflict}(d_i, d_j) \iff \text{area}(d_i) \neq \text{area}(d_j) \wedge \text{Hamming}(\text{simhash}(d_i), \text{simhash}(d_j)) > \tau_{\text{conflict}} = 26 \tag{45}$$

大哈密顿距离 $\tau_{\text{conflict}} > 26$ 指示两个文档在语义空间中的方向完全分离——物理上等价于在 64 维超立方体 $(\mathbb{Z}_2)^{64}$ 中占据对极位置。

对极位置的几何意义：将汉明距离 Hamming > 26 转换回角度空间：在 64 维超立方体中，汉明距离 k 对应球面上的期望夹角约为 $\pi \cdot k/64$。Hamming $= 26$ 对应夹角 $\approx 0.41\pi \approx 73°$，意味着两个文档在语义球面上的方向至少偏离了 73°——几乎正交，代表了显著的语义分歧。

5.3 区域共识得分

$$s_{\text{consensus}}(a) = \frac{1}{|\mathcal{D}_a|} \sum_{d \in \mathcal{D}_a} s_{\text{sim}}(d), \quad \mathcal{D}_a = \{d \in \text{unique_docs} : \text{area}(d) = a\} \tag{46}$$

共识得分的统计力学解释： $s_{\text{consensus}}(a)$ 是领域 a 中文档群体的" 系综平均"。在统计力学中，系综平均反映系统的宏观可观测量；在这里，它反映该疾病领域中知识的一致性程度——高共识分意味着该领域的知识高度一致（多个来源指向相同结论），低共识分意味着该领域存在争议或不确定性。

6 验证智能体 (Verification Agent)

6.1 事实核对评分

$$s_{\text{fact}}(d) = \text{clip}_{[0.0,1.0]}\left(0.38 + b_{\text{auth}} + b_{\text{content}} + b_{\text{area}} + b_{\text{med}} + b_{\text{evidence}} - p_{\text{redflag}} - p_{\text{vague}}\right) \tag{47}$$

各子项：

- $b_{\text{auth}} = 0.20$ 若来源为权威源或人类专家
- $b_{\text{content}} = \min(0.30, 0.06\sqrt{|\text{tokens}(d)|})$
- $b_{\text{area}} = 0.10$ 若领域非 Unknown
- $b_{\text{med}} = \min(0.15, 0.04 \cdot \#\text{med_terms_hit})$
- $b_{\text{evidence}} = 0.14$ 若含定量数据或研究引用
- $p_{\text{redflag}} = 0.35$ 若含伪科学/危险关键词
- $p_{\text{vague}} = 0.15$ 若标记数 < 12

注 6.1 (评分函数的结构). s_{fact} 的结构是一个**加性证据模型**：基线分 (0.38) + 正证据项 (b_*) − 负证据项 (p_*)。基线分 0.38 代表" 无信息先验"——没有任何证据时，文档的正确概率基准。$b_{\text{content}} = 0.06\sqrt{n}$ 使用平方根标度（而非线性）反映信息量的 **递减边际效益**——200 个 token 带来的信息增量并非 100 个 token 的 2 倍，而是约 1.4 倍。$p_{\text{redflag}} = 0.35$ 是最大的单项惩罚——一旦检测到危险信号，文档可信度大幅下降（从 0.38 降至 0.03），反映了医疗领域对安全性的极致要求。

6.2 时效性检查

$$\text{timeliness_ok}(d) \iff \Delta t = (\text{now} - \text{last_updated}(d))_{\text{days}} \leq 365 \tag{48}$$

6.3 TFA 报告验证

对 TFA 输出执行四项检查：风险得分范围检查（$r \in [0, 1]$）、风险因子-诊断关联性检查、推荐-风险等级一致性检查、退化通知检查。

7 隐私智能体 (Privacy Agent)

7.1 差分隐私的数学基础

隐私智能体在信息论安全与计算效率之间取得平衡，其核心是高斯差分隐私机制。

7.2 联邦梯度扰动

$$\nabla^{\text{secure}} = \nabla^{\text{raw}} + \boldsymbol{\epsilon}, \quad \epsilon_i \sim \mathcal{N}(0, \sigma_{\text{noise}}^2), \quad \sigma_{\text{noise}} = 0.015 \tag{49}$$

这等同于满足局部 (ϵ, δ)-差分隐私的高斯机制，其中隐私预算 ϵ 由 σ_{noise} 和敏感度 Δf 决定：

$$\epsilon \approx \frac{\Delta f}{\sigma_{\text{noise}}} \cdot \sqrt{2\log(1.25/\delta)} \tag{50}$$

注 7.1 ($\sigma_{\text{noise}} = 0.015$ 的选择依据). 噪声标准差 0.015 是在隐私保护与模型效用之间的工程权衡。

敏感度分析：在 HMAE 的实际实现中，每个样本的梯度经 L2 裁剪至最大范数 $C = 1.0$，因此敏感度 $\Delta f = C = 1.0$。代入高斯机制隐私预算公式：$\sigma \geq \frac{\Delta f}{\varepsilon} \cdot \sqrt{2\log(1.25/\delta)}$，取 $\delta = 10^{-5}$，可得 $\varepsilon \approx 2.2$，满足医疗场景下的差分隐私要求。实际实现中使用梯度裁剪（norm clip $= 1.0$）。

在 HMAE 中，梯度值通常经 L2 归一化后分布于 $[-1, 1]$，因此 $\sigma = 0.015$ 意味着信噪比 SNR $\approx 1/0.015^2 \approx 4400$（在方差意义上）。这提供了足够强的隐私保护（任何单个数据点的影响被噪声模糊化），同时保持梯度方向的基本可用性。

7.3 XOR 流加密

$$c_k = p_k \oplus \text{key}_{k \bmod |K|}, \quad K = \text{SHA-256}(\text{secret_key}) \tag{51}$$

物理意义上，这是具有一次性密码本安全特性的流加密方案——密钥长度等于消息长度时达到信息论安全。SHA-256 的输出是 256 位的均匀分布伪随机序列，对抗已知明文攻击的安全性依赖于 SHA-256 的原像抗性。

8 维护智能体 (Maintenance Agent)

8.1 心跳监测

对每个已注册智能体 $a \in \mathcal{A}$：

$$\text{status}(a) = \begin{cases} \text{faulty} & \text{if } \Delta t = \text{now} - a.\text{last_heartbeat} > \tau_{\text{timeout}} = 120\text{s} \\ a.\text{status} & \text{otherwise} \end{cases} \tag{52}$$

超时阈值的控制论解释： $\tau_{\text{timeout}} = 120s$ 定义了一个”软实时”约束。在控制论中，这是一个**死区时间（dead time）**——超过此时间无响应的组件被视为失效，系统切换到降级模式。

8.2 异常输出检测

$$\text{abnormal}(y) = \begin{cases} \text{True} & \text{if } y \text{ is None} \vee \text{NaN}(y) \vee \text{Inf}(y) \\ \text{True} & \text{if } y.\text{confidence is None} \vee \text{NaN}(y.\text{confidence}) \\ \text{False} & \text{otherwise} \end{cases} \tag{53}$$

9 通信拓扑智能体 (Topology Manager)

9.1 网络模型

星型拓扑：中心节点为 DMA，所有通信经 DMA 路由：

$$\mathcal{E}_{\text{star}} = \{(a, \text{DMA}) \mid a \neq \text{DMA}\} \cup \{(\text{DMA}, a) \mid a \neq \text{DMA}\} \tag{54}$$

网状拓扑：全对等通信：

$$\mathcal{E}_{\text{mesh}} = \{(a, b) \mid a, b \in \mathcal{A}, a \neq b\} \tag{55}$$

拓扑选择的图论分析：星型拓扑的图直径为 2（任意两个非中心节点通过 DMA 中继只需 2 跳），通信复杂度为 $O(|\mathcal{A}|)$，适合节点数量适中、需要中心化控制的场景。网状拓扑的图直径为 1，但通信复杂度为 $O(|\mathcal{A}|^2)$，适合需要低延迟全对等通信的场景。HMAE 的拓扑管理器支持动态切换，根据系统退化状态选择最优拓扑。

9.2 路由路径

对于发送方 s 和接收方 r：

$$\text{path}(s, r) = \begin{cases} [s, r] & \text{if } r \in \mathcal{N}(s) \\ [s, \text{DMA}, r] & \text{if DMA} \in \mathcal{N}(s) \wedge r \in \mathcal{N}(\text{DMA}) \\ \emptyset & \text{otherwise} \end{cases} \tag{56}$$

9.3 消息重试队列

传输失败的消息进入 FIFO 队列 Q，重试时重新计算路由路径，若仍不可达则放回队尾。

10 共识智能体 (Consensus Module)

10.1 投票权重分配

投票方	权重	角色
DMA (诊断)	2	核心诊断决策
TFA (时序风险)	1	辅助决策支持
Verification (验证)	1	事实核查
总计	4	通过阈值 = 3 (75%)

注 10.1 (加权投票的机制设计原理). 权重分配 $[2,1,1]$ 和通过阈值 $3/4 = 75\%$ 满足以下机制设计约束：

- DMA (权重 2) 不能单独通过任何决策（$2 < 3$）——防止诊断独裁
- DMA + 任一方 = 3，可以通过——诊断 + 辅助支持或诊断 + 事实核查即可决策
- TFA + Verification (权重 1+1=2) 不足通过（$2 < 3$）——没有诊断支持的纯辅助信号不能独立决策

这是一种巧妙的**制衡（checks and balances）**设计：DMA 作为核心但受制约，单一方不能独裁，多方联合才能形成决策。在博弈论中，这构成一个**加权多数博弈（weighted majority game）**，其 Shapley 值为 DMA > TFA = Verification，反映了 DMA 的核心地位。

10.2 三层级协同决策

第 1 层—FORCE_HITL（强制人工介入）：若有任一条成立则绕过投票直接转人工：

- DMA 置信度 < 阈值 0.62（或已触发 HITL 标记）
- 验证严重冲突 ≥ 1
- TFA 风险等级 = critical
- TFA-诊断冲突 ≥ 1

第 2 层—DMA_VETO（诊断否决）：

$$\text{approved} = \text{False} \quad \text{if } \gamma_{\text{DMA}} < \tau_{\text{confidence}} = 0.62 \tag{57}$$

第 3 层—NORMAL_VOTE（标准投票——置信度 × 风险矩阵）：

$$\text{decision}(\gamma_{\text{DMA}}, r_{\text{TFA}}) = \begin{cases} \text{AUTO_PASS} & \gamma \geq 0.8 \wedge r \in \{\text{low}, \text{medium}\} \\ \text{PASS_RISK_NOTED} & \gamma \geq 0.8 \wedge r = \text{high} \\ \text{AUTO_PASS} & 0.6 \leq \gamma < 0.8 \wedge r = \text{low} \\ \text{ESCALATE} & 0.6 \leq \gamma < 0.8 \wedge r \in \{\text{medium}, \text{high}\} \\ \text{ESCALATE} & \gamma < 0.6 \end{cases} \tag{58}$$

注 10.2 (三层级决策的临床安全逻辑). 三层级架构体现了**安全优先（safety-first）**的设计原则：

第 1 层 (FORCE_HITL) - 最高优先级，绝对安全网：任何一条高危信号（极低置信度、严重冲突、critical 风险）直接触发人工介入，不经过任何投票。

第 2 层 (DMA_VETO) - DMA 作为" 守门人"：即使通过第 1 层，DMA 仍然可以一票否决（当自身置信度不足时）。这是保证" 不做出不可靠诊断" 的最后防线。

第 3 层 (NORMAL_VOTE) - 常规操作：在安全前提下，通过置信度 × 风险矩阵进行精细决策。$\gamma \geq 0.8$ 且低/中风险时自动通过；$\gamma < 0.6$ 时一律升级——体现了" 不确定时宁可升级也不冒险" 的原则。

11 纳什均衡检索策略选择

11.1 博弈论框架

RAA 策略空间 $\mathcal{S} = \{\text{mixed}, \text{rerank}, \text{adaptive}\}$，DMA 模式空间 $\mathcal{M} = \{\text{fast}, \text{balanced}, \text{deep}\}$。效用函数：

$$U(s, m) = \lambda \cdot P(\text{correct} \mid q, \mathcal{K}_s, m) - (1 - \lambda) \cdot C(s, |\mathcal{K}_s|) \tag{59}$$

其中 $\lambda = 0.72$（精度-成本权衡因子），$C(s, n)$ 为检索成本：

$$C(s, n) = \begin{cases} 0.22 + 0.012n & s = \text{mixed} \\ 0.36 + 0.012n & s = \text{rerank} \\ 0.28 + 0.012n + 0.08 \cdot \mathbb{I}[U(q) > 0.58] & s = \text{adaptive} \end{cases} \tag{60}$$

$\lambda = 0.72$ **的决策论含义**：精度权重远高于成本权重 $(0.72 > 0.28)$。在医疗场景中，这是必然的选择——错误诊断的代价远大于额外计算资源。$\lambda : (1 - \lambda) \approx 2.57 : 1$ 的比率体现了" 宁可多花计算也要保证准确性" 的先验。

11.2 最佳反应迭代

$$s^{(t+1)} = \arg\max_{s \in \mathcal{S}} U(s, m^{(t)}) \tag{61}$$

$$m^{(t+1)} = \arg\max_{m \in \mathcal{M}} \left[\lambda \cdot \hat{P}(\text{correct} \mid \mathcal{K}_{s^{(t+1)}}, m) - (1 - \lambda) \cdot C(s^{(t+1)}, |\mathcal{K}|) \right] \tag{62}$$

迭代至纳什均衡 (s^*, m^*) 满足：$U(s^*, m^*) \geq U(s, m^*)\ \forall s$ 且 $U(s^*, m^*) \geq U(s^*, m)\ \forall m$，最多迭代 $N_{\max} = 6$ 轮。

11.3 收敛条件

$$\text{Converged}^{(t)} \iff s^{(t)} = s^{(t-1)} \wedge m^{(t)} = m^{(t-1)} \tag{63}$$

注 11.1 (势博弈与收敛保证). 式 (59) 定义了一个有限策略空间中的**势博弈（potential game）**——势函数 $\Phi(s,m) = \lambda P - (1-\lambda)C$ 在每次最佳响应更新中单调不减：$\Phi(s^{(t+1)}, m^{(t+1)}) \geq \Phi(s^{(t)}, m^{(t)})$。由于策略空间有限（$3 \times 3 = 9$ 个纯策略组合），势函数的单调性保证算法在最多 9 步内收敛（实际限制 $N_{\max} = 6$ 轮已足够检测循环）。这一收敛性质是确定的、可证明的——不需要随机性假设。

第二部分 其他部分——Supporting Modules & Infrastructure

12 动态知识库 (Online Knowledge Base)

12.1 增量知识更新

$$\mathcal{K}_{t+1} = \mathcal{K}_t \cup \{\text{Embed}(L_{\text{new}})\} \tag{64}$$

其中 L_{new} 为来自 PubMed、arXiv、UpToDate、IEEE Xplore 的新文献。

单调性保证：知识库的更新是**单调非减的**——$\mathcal{K}_{t+1} \supseteq \mathcal{K}_t$。这意味着系统知识只增不减（除非人工删除），确保历史决策的可追溯性。在逻辑上，这构成一个**增长的知识理论**——新知识可能与旧知识冲突（通过融合智能体的冲突检测处理），但不会消除旧知识。

12.2 文档权重反馈更新

$$w_{\text{doc}}^{(t+1)} = \text{clip}\left(w_{\text{doc}}^{(t)} + \eta \cdot F_{\text{user}} \cdot \nabla_{\text{proxy}}\right)_{0.20}^{2.50} \tag{65}$$

其中 $\eta = 0.08$（学习率），$F_{\text{user}} \in \{-1, 0, +1\}$（人类反馈信号），$\nabla_{\text{proxy}} = \|\text{MiniLM}(q)\|_2$（查询强度代理梯度）。

式 (65) 是随即梯度下降在离散反馈空间中的实例化：文档权重沿反馈信号方向移动，以最大化未来检索质量。裁剪区间 $[0.20, 2.50]$ 确保权重不会因极端反馈而发散——即使连续的负面反馈也不会使权重低于 0.20（保留基本的检索可能性），连续的正面反馈也不会使权重超过 2.50（防止某些文档垄断检索结果）。

12.3 FAISS 索引重建

$$\mathbf{M}_{\text{dense}} = \text{MiniLM}(\mathcal{D}) \in \mathbb{R}^{|\mathcal{D}| \times d} \tag{66}$$

$$\text{Index}_{\text{FAISS}} = \text{IndexFlatIP}(d) \tag{67}$$

$$\text{Index}_{\text{FAISS}}.\text{add}(\mathbf{M}_{\text{dense}}) \tag{68}$$

13 三源知识融合 (Tri-Source Fusion)

13.1 信源加权融合

给定三组文档 $\mathcal{D}_{\text{human}}$（人类经验）、$\mathcal{D}_{\text{auth}}$（权威知识）、$\mathcal{D}_{\text{ret}}$（检索知识），融合得分为：

$$s_{\text{fused}}(d) = \text{clip}\left(s(d) \cdot w_{\text{source}} + 0.05 \cdot w_{\text{doc}}(d)\right) \tag{69}$$

其中信源权重：$w_{\text{human}} = 0.95$, $w_{\text{auth}} = 0.90$, $w_{\text{ret}} = 0.75$, $w_{\text{synth}} = 0.55$。

融合操作在物理上等价于多信源的贝叶斯加权汇聚——高可信度信源具有更大的似然权重。

注 13.1 (信源权重的层级结构). 权重递减链 $0.95 \to 0.90 \to 0.75 \to 0.55$ 反映了**证据可靠性层级**：人类专家判断 $>$ 权威出版物 $>$ 通用检索结果 $>$ 合成知识。此层级结构不是线性的——人类与权威之间的差距 (0.05) 小于权威与通用检索之间的差距 (0.15)，体现了" 同行评审的知识与专家知识接近但次之，开放检索的未过滤知识需要显著折价" 的认知论立场。

14 知识蒸馏引擎 (Knowledge Distillation)

14.1 加权平均上下文向量

对 top-k 文档，计算相似度加权的平均语义向量：

$$\mathbf{v}_{\text{distill}} = \text{L2}\left(\frac{\sum_{i=1}^{k} s_i \cdot \mathbf{v}_i}{\sum_{i=1}^{k} s_i}\right), \quad s_i = \max(s_{\text{sim}}(d_i), 10^{-3}) \tag{70}$$

此操作在余弦相似度度量下的几何意义是：在单位超球面 S^{d-1} 上，求文档向量的 **Fréchet 均值**（黎曼重心）。与欧几里得空间中的算术平均不同，球面上的" 平均" 必须考虑球面曲率——Fréchet 均值是使得所有文档向量到它的测地线距离平方和最小的那个点：$\mathbf{v}_{\text{distill}} = \arg\min_{\mathbf{v} \in S^{d-1}} \sum_i s_i \cdot d_{\text{geo}}(\mathbf{v}, \mathbf{v}_i)^2$。加权平均公式是此优化问题在局部切空间中的一阶近似解。

15 人在回路管理 (HITL Manager)

15.1 三层干预架构

第 1 层—自主执行：系统独立做出决策。**第 2 层—人工干预判定**：

$$\text{HITL}^{(t)} \iff \gamma_{\text{DMA}} < \tau_{\text{conf}} \vee \bar{s}_{\text{ret}} < \tau_{\text{ret}} \vee (r_{\text{TFA}} \geq \tau_{\text{risk}} \wedge \text{high_risk}) \tag{71}$$

其中 $\tau_{\text{conf}} = 0.62$, $\tau_{\text{ret}} = 0.24$, $\tau_{\text{risk}} = 0.65$。**第 3 层—参数与检索更新**：基于人类纠正更新 DMA 校准和检索权重。

L1/L2/L3 的分层逻辑：这三层形成了完整的**自主-监督-学习**闭环：L1 是正常操作模式（系统独立运行），L2 是安全网（条件触发人工审查），L3 是反馈学习（将人工判断转化为参数更新）。三层合在一起构成了一个 **人在回路的持续改进系统 (Human-in-the-Loop Continuous Improvement System)**。

15.2 TFA 特异性 HITL

优先级系统：

- Priority 1 (critical)：TFA 风险等级 critical ——立即干预
- Priority 2 (conflict)：TFA 与 DMA 诊断冲突——紧急审查
- Priority 3 (warning)：TFA 退化或验证警告——建议审查

15.3 错误分类与诊断

三型错误体系：

$$E_{\text{missing}} : \text{检索覆盖中缺少正确疾病领域} \tag{72}$$

$$E_{\text{misleading}} : \text{高分检索片段支持竞争疾病领域} \tag{73}$$

$$E_{\text{bias}} : \text{证据存在但 DMA 决策边界需校准} \tag{74}$$

三型错误的诊断价值：这三种错误的划分不是随意的——它们分别对应诊断流程中的三个不同阶段：E_{missing} 是**检索阶段**的失败（知识库不完整），$E_{\text{misleading}}$ 是**证据评估阶段**的失败（证据权重分配错误），E_{bias} 是**决策阶段**的失败（先验/偏置校准不当）。通过区分这三类错误，HITL 可以针对性地修复系统的不同组件。

16 模拟 LoRA 微调 (Simulated LoRA Fine-Tuner)

16.1 隐私感知梯度聚合

$$\nabla_{\text{agg}} = \frac{1}{N}\sum_{i=1}^{N} \text{sign}_i \cdot \text{MiniLM}(q_i) \in \mathbb{R}^d \tag{75}$$

$$\text{sign}_i = \begin{cases} +1.0 & \text{label}(q_i) \neq \text{pred}(q_i) \\ +0.25 & \text{otherwise} \end{cases} \tag{76}$$

$$\nabla_{\text{secure}} = \nabla_{\text{agg}} + \boldsymbol{\epsilon}, \quad \epsilon_j \sim \mathcal{N}(0, 0.015^2) \tag{77}$$

非对称梯度信号的设计：误分类样本产生 $+1.0$ 的强梯度信号，正确分类样本产生 $+0.25$ 的弱信号。这 $4:1$ 的比例反映了 **错误驱动的学习（error-driven learning）**——从错误中学习的效率应远高于从成功中巩固的效率。在神经科学中，这对应**预测误差驱动的突触可塑性**（dopamine-modulated STDP）。

16.2 校准因子更新

$$f_{\text{cal}}^{(t+1)} = \text{clip}\left(f_{\text{cal}}^{(t)} + 0.04 \cdot \frac{1}{N}\sum_i (1-\gamma_i)\right)_{0.80}^{1.35} \tag{78}$$

16.3 类比偏差累积

$$b_c^{(t+1)} = b_c^{(t)} + 0.03 \cdot \frac{\#\{i : \text{corrected_label}(i) = c\}}{N} \tag{79}$$

偏差累积的贝叶斯解释：类偏差 b_c 实现了**在线贝叶斯先验更新：**每当人类将某个预测纠正为类 c，该类别的先验概率微增——这意味着系统学会了" 在不确定时，稍微偏向这个经常被纠正为正确的类别"。学习率 0.03 确保了单个纠正不会剧烈改变行为，而持续的模式会逐渐塑造决策边界。

17 对比检索更新 (Contrastive Retrieval Updater)

17.1 检索裕度偏移

$$\Delta m = \text{clip}\left(m + \eta_g \cdot \frac{N_+ - N_-}{N_+ + N_-}\right)_{-0.25}^{0.25}, \quad \eta_g = 0.02 \tag{80}$$

此更新规则来源于对比损失 $\mathcal{L}_{\text{contrast}} = -\log \frac{\exp(s_+)}{\exp(s_+)+\exp(s_-)}$ 的梯度方向。

对比学习的几何解释：对比损失在嵌入空间中施加一个" 推-拉" 动力学——正样本（相关文档）被拉向查询向量，负样本（不相关文档）被推离查询向量。最终的稳态是：正样本围绕查询向量形成一个紧致的簇，负样本被驱离到球面的远处。

18 退化管理 (Degradation Manager)

18.1 三级退化机制

$$L = \begin{cases} 0 \text{ (NORMAL)} & \text{unavailable} = 0 \wedge \text{degraded} = 0 \\ 1 \text{ (MINOR)} & \text{unavailable} = 0 \wedge \text{degraded} \geq 1 \\ 2 \text{ (PARTIAL)} & \text{unavailable} \geq 1 \vee \text{degraded} \geq 2 \\ 3 \text{ (SEVERE)} & \text{unavailable} \geq 3 \end{cases} \tag{81}$$

`safe_call` 模式保证任意组件失败时系统残存运行：捕获异常 $\rightarrow$ 标记组件状态 $\rightarrow$ 返回回退值。

注 18.1 (退化管理与控制论中的优雅降级). 退化等级 $L \in \{0, 1, 2, 3\}$ 构成了一个**序数安全尺度**。在控制论中，这对应**容错控制 (fault-tolerant control)** 的层级：

$L = 0$: 全功能运行

$L = 1$: 部分组件退化但核心功能保持（如 4-bit 量化替代全精度）

$L = 2$: 部分组件不可用但替代路径存在（如 Llama3 路径失效，回退至质心分类）

$L = 3$: 大部分组件失效，进入保守安全模式（仅使用最基础的规则决策）

19 持续学习循环 (Continuous Learning Loop)

19.1 触发条件与周期执行

$$\text{should_update} \iff |\mathcal{F}_{\text{buffer}}| \geq n_{\min} = 10 \tag{82}$$

每个周期：

1. DMA Platt 校准更新（SGD 200 步）
2. 检索权重对比更新（最近 20 条反馈）
3. 反馈缓冲清空
4. 精度趋势估计：$\hat{a} = 1 - \#\text{corrections}/|\mathcal{F}_{\text{buffer}}|$

在线学习的工程约束： $n_{\min} = 10$ 的选择是在" 及时学习" 和" 统计稳定性" 之间的权衡。太小的批量（如 1）使每次更新噪声过大（高方差梯度估计），太大的批量（如 100）延迟反馈的利用（系统适应慢）。10 是一个经验上的平衡点。

20 MedTsLLM-v1.5 适配器

20.1 BioBERT 冻结骨干

使用 dmis-lab/biobert-v1.1（108M 参数，$d_{\text{LLM}} = 768$）作为冻结编码器：

$$\forall \theta \in \Theta_{\text{BioBERT}} : \frac{\partial \mathcal{L}}{\partial \theta} = 0 \tag{83}$$

冻结骨干的参数效率原理： BioBERT 已经在生物医学语料上预训练，其内部表征已经捕获了丰富的医学语义。冻结骨干确保这些宝贵的预训练知识不被小批量时序数据" 灾难性遗忘"，而仅通过轻量的 Reprogramming Layer 和 FlattenHead 进行任务特定适配。总可训练参数量约为 BioBERT 的 2%（ 2M / 108M），大幅降低了部署和微调成本。

20.2 时间序列 $\rightarrow$ 语言空间重编程

核心数学操作：重编程层通过交叉注意力将离散时序分块映射到连续语义空间：

$$\text{Reprogrammed}(t) = \text{OutProj}\left(\text{softmax}\left(\frac{\mathbf{Q}(t)\mathbf{K}(\mathcal{W})^{\top}}{\sqrt{E}}\right)\mathbf{V}(\mathcal{W})\right) \tag{84}$$

其中 $\mathcal{W}$ 为 BioBERT 词表嵌入，$\mathbf{Q}(t)$ 为时序分块查询，$\mathbf{K}(\mathcal{W}), \mathbf{V}(\mathcal{W})$ 为词汇键/值投影。

物理意义：Reprogramming Layer 是一个**信息瓶颈 (information bottleneck)** ——它将高维连续时序信号压缩到离散语言符号空间，利用 LLM 的预训练语义先验重构预测。压缩-重构的平衡由维度 $d_{\text{ff}} = 256$ 和头数 $n_{\text{heads}} = 8$ 控制。

信息瓶颈的率失真理论解释： 在 Tishby 的信息瓶颈理论中，最优表征在" 压缩输入信息" 和" 保持任务相关信息" 之间取得平衡。Reprogramming Layer 通过交叉注意力实现了一个**软瓶颈**——时序信息必须通过离散语言符号构成的" 窄通道"，只有与 BioBERT 的语义空间兼容的信息分量才能通过。这自然地过滤了时序噪声，保留了医学上可解释的信号。

20.3 输出投影与风险解耦

$$\mathbf{r}_{\text{output}} = \sigma\left(\text{FlattenHead}(\mathbf{h}_{\text{TS}})\right) \in [0,1]^{3\times 3} \tag{85}$$

三维输出分别对应：短 (24h)、中 (30d)、长 (12m) 期风险 × 三通道（恶化/稳定/恢复）。

第三部分 相互联系——Inter-Module Coupling & System Dynamics

21 端到端流水线数据流

$$\underbrace{X_{\text{txt}} + X_{\text{img}}}_{\text{输入}} \xrightarrow{\S1} \underbrace{\mathbf{v}_{\text{fused}}}_{\text{感知}} \xrightarrow{\S2,\,\S11} \underbrace{\mathcal{K}_s}_{\text{检索}} \xrightarrow{\S5} \underbrace{\mathcal{D}_{\text{fused}}}_{\text{融合}} \xrightarrow{\S6} \underbrace{\mathcal{D}_{\text{verified}}}_{\text{验证}}$$

$$\xrightarrow{\S7} \underbrace{\mathbf{v}_{\text{distill}}}_{\text{蒸馏}} \xrightarrow{\S3} \underbrace{\{P(c|q), \hat{c}\}}_{\text{DMA}} \xrightarrow{\S4} \underbrace{\{r_s, r_m, r_l\}}_{\text{TFA}} \xrightarrow{\S8,\,\S10}$$

$$\underbrace{\text{decision}}_{\text{HITL + 共识}}$$

图 1: 端到端流水线数据流

流水线的马尔可夫性质：注意数据流是单向的（虽然有反馈环路用于学习更新）。这意味着一次推理的前向传播满足**马尔可夫性质：**每个模块的输出仅依赖于前一个模块的输出（和自身的内部状态），不直接依赖于更早的模块。这一性质极大地简化了系统的调试和分析——错误可以通过逐模块的溯源来定位。

22 耦合矩阵——跨模块信息依赖

耦合方向	耦合机制 / 数学关系
Perception → RAA	$\mathbf{v}_{\text{fused}}$ 作为上下文强度输入
Perception → DMA	$\mathbf{v}_{\text{fused}}$ 作为 DMA 上下文加权
RAA → DMA	$\mathcal{K}_s$（检索文档）→ 检索得分、上下文构建
RAA → TFA	风险感知检索：$\mathcal{K}_{\text{risk}}$ → TFA-RA 一致性
RAA ↔ DMA (博弈论)	$s \leftrightarrow m$ 纳什均衡迭代 (式 59)
DMA → TFA	γ_{DMA} → TFA 置信度校准因子
TFA → Consensus	r_{TFA} → 投票 ($w_{\text{TFA}} = 1$)
TFA → HITL	风险等级 → 干预触发
Verification → Consensus	验证通过率 → 投票 ($w_{\text{Ver}} = 1$)
HITL → DMA	反馈 → Platt 校准 + 类偏差更新
HITL → KB	正/负文档 ID → 权重更新 (式 65)
Fusion → Verification	冲突文档 ID → 严格事实阈值
Distillation → DMA	$\mathbf{v}_{\text{distill}}$ 与 $\mathbf{v}_{\text{fused}}$ 线性混合
TFA → RAA	风险等级 → 风险特定文档增强检索

表 1: 跨模块耦合矩阵

耦合矩阵的图论分析：将此矩阵视为有向图 $G = (V, E)$，其中 V 为模块集合，E 为耦合关系。该图具有以下性质：

- **弱连通性**：任何两个模块之间至少在一个方向上存在路径
- **DMA 中心性**： DMA 的出度和入度都是最大的——它是信息流的核心枢纽
- **闭环存在性**：HITL → DMA → TFA → HITL 构成反馈闭环——这是持续学习的基础
- **无自环**：所有耦合都是跨模块的，无模块直接反馈到自身

23 通信拓扑：星型网络上的信息传播

在星型拓扑下，所有消息经 DMA 中继：

$$\mathcal{M}_{A\to B}(t) = \text{Route}(A \to \text{DMA} \to B)(t) \tag{86}$$

消息传递动力学（含隐私加密）：

$$\mathcal{M}_{\text{enc}} = \text{XOR}_{\text{SHA-256}}(\text{payload}), \quad \mathcal{M}_{\text{dec}} = \text{XOR}^{-1}_{\text{SHA-256}}(\mathcal{M}_{\text{enc}}) \tag{87}$$

24 系统整体平衡方程

HMAE 系统可视为受以下约束的随机动力系统：

$$\text{(状态演化)} \quad \mathbf{S}_{t+1} = f(\mathbf{S}_t, \mathbf{u}_t, \boldsymbol{\xi}_t) \tag{88}$$

$$\text{(观测)} \quad \mathbf{y}_t = g(\mathbf{S}_t, \boldsymbol{\eta}_t) \tag{89}$$

$$\text{(决策)} \quad a_t = \pi(\mathbf{S}_t, \mathcal{K}_t) \tag{90}$$

$$\text{(反馈学习)} \quad \Theta_{t+1} = \Theta_t - \eta \cdot \nabla_\Theta \mathcal{L}(\mathbf{y}_t^{\text{true}}, \mathbf{y}_t^{\text{pred}}) \tag{91}$$

其中：

- $\mathbf{S}_t$ —系统状态（KB 索引、模型参数、文档权重）
- $\mathbf{u}_t$ —控制输入（检索策略 s、决策模式 m）
- $\boldsymbol{\xi}_t, \boldsymbol{\eta}_t$ —噪声项（输入噪声 $\sim 10\%$-30%、梯度噪声 $\sim \mathcal{N}(0, 0.015^2)$）
- $\mathcal{K}_t$ —时变知识库（$\mathcal{K}_{t+1} \supseteq \mathcal{K}_t$，单调解构更新）
- Θ_t —可学习参数（Platt (A, B)、LoRA 类偏差、文档权重）

注 24.1 (随机动力系统视角下的 HMAE). 从上述平衡方程可以看出，HMAE 是一个**受控随机动力系统**。其关键数学结构是：

- **状态空间 $\mathcal{S}$**：维度极高（KB 索引 $\sim 10^5$ 维 + 嵌入向量 ~ 128 维 + 参数 $\sim 10^4$ 维）
- **控制空间 $\mathcal{U}$**：离散且有限（$3 \times 3 = 9$ 个选择）
- **动态**：混合了确定性更新（f）和随机扰动（$\boldsymbol{\xi}$）
- **稳定性**：由退化管理和 HITL 保证——当系统状态偏离安全区域时，强制回退到保守策略

这是典型的**混合系统 (hybrid system)**：连续状态 + 离散控制 + 随机噪声。

25 物理类比总结

HMAE 组件	**物理类比**	**守恒量/不变量**
SimHash 去重	64 维超立方体编码	汉明距离度量
Softmax $T = 0.18$	低温极限—基态提取	自由能极小化
Platt 校准	最大熵原则下的 logistic 校正	交叉熵一致
RevIN 归一化	可逆正则变换	$p(x; \mu, \sigma)$ 分布保持
TFA 门控融合	量子叠加态坍缩	$\sum g_k = 1$ (概率完备)
纳什均衡搜索	势博弈单调解	$\Phi(s, m)$ 单调不减
FAISS 内积搜索	高维空间最大投影	$\cos(\theta)$ 保序
知识蒸馏	Fréchet 均值	球面测地线极小化
隐私梯度扰动	高斯差分隐私机制	(ϵ, δ)-DP 保证
检索成本函数	拉格朗日对偶	$\lambda P - (1 - \lambda) C$ 权衡
退化管理	工程容错控制理论	安全状态可达性
连续学习	在线随机梯度下降	$\mathbb{E}[\mathcal{L}]$ 期望递减

表 2: HMAE 物理类比映射表

第四部分　输出结果分析——Output Analysis & Evaluation Framework

26　评价指标体系

26.1　分类指标

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \tag{92}$$

$$\text{Precision}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FP}_c} \tag{93}$$

$$\text{Recall}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FN}_c} \tag{94}$$

$$F1_c = 2 \cdot \frac{\text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \tag{95}$$

宏观/微观/加权三种平均方式：

$$P_{\text{macro}} = \frac{1}{|\mathcal{C}|} \sum_c P_c, \quad P_{\text{micro}} = \frac{\sum_c \text{TP}_c}{\sum_c (\text{TP}_c + \text{FP}_c)} \tag{96}$$

$$F1_{\text{weighted}} = \sum_c \frac{|\mathcal{D}_c|}{|\mathcal{D}|} \cdot F1_c \tag{97}$$

三种平均方式的适用场景： Macro（宏平均）给所有类同等权重，适合关注罕见病的场景（罕见病与常见病同等重要）；Micro（微平均）给所有样本同等权重，适合评估整体系统表现；Weighted（加权平均）给大类更多权重，适合关注总体临床效果的场景。

26.2　消融实验指标

$$\Delta_{\text{module}} = \text{Acc}(\text{full}) - \text{Acc}(\text{without_module}) \tag{98}$$

测量 HITL、TFA、Multimodal 各模块的边际贡献。

26.3　噪声鲁棒性指标

$$R(\sigma) = \frac{\text{Acc}(\text{noise} = \sigma)}{\text{Acc}(\text{noise} = 0)}, \quad \sigma \in \{0.10, 0.30\} \tag{99}$$

26.4　数据规模适应性指标

$$\eta_{\text{scale}}(f) = \frac{\text{F1}(f \cdot |\mathcal{D}_{\text{train}}|)}{\text{F1}(|\mathcal{D}_{\text{train}}|)}, \quad f \in \{0.20, 0.50, 0.80, 1.00\} \tag{100}$$

26.5 常见/罕见病差异指标

$$\Delta_{\text{rare}} = \frac{\text{F1}_{\text{common}} - \text{F1}_{\text{rare}}}{\text{F1}_{\text{common}}} \tag{101}$$

$\Delta_{\text{rare}} > 0.30$ 指示罕见病检索覆盖不足或训练数据长尾效应。

27 系统级输出分析

27.1 TFA 风险预测输出结构

每次 TFA 预测产生三个时间窗口的风险概率向量：

$$\mathbf{r}_{\text{TFA}} = [r_s, r_m, r_l]^\top \in [0,1]^3 \tag{102}$$

其联合分布定义了一个三维风险流形 $\mathcal{M}_{\text{risk}} \subset [0,1]^3$。对角元素对应" 恶化-稳定" 二项分布：$P(\text{deteriorate}) = r_s$, $P(\text{stable}) = 1 - r_s$。

27.2 共识决策输出结构

共识模块产生分层决策向量：

$$\mathbf{d}_{\text{consensus}} = [\text{approved}, \text{tier}, \text{votes}, \text{risk_level}, \text{escalate_to_human}] \tag{103}$$

其中 $\text{tier} \in \{\text{force_hitl}, \text{dma_veto}, \text{auto_pass}, \text{auto_pass_risk_noted}, \text{escalation_risk_uncertainty}\}$。

27.3 系统综合答案 (Comprehensive Answer)

融合模块输出统一的临床答案结构：

- `diagnosis`: $\{\text{prediction}, \text{confidence}, \text{severity}, \text{intent}, \text{status}\}$
- `risk_assessment`: $\{\text{risk_level}, \text{risk_score}, [r_s, r_m, r_l], \text{factors}, \text{reasoning}\}$
- `recommendations`: 分层临床建议（基于 TFA 风险等级）
- `disclaimer`: 医疗免责声明

28 消融实验分析框架

条件	HITL	TFA	Multimodal
完整生态系统	✓	✓	✓
无 HITL	×	✓	✓
无 TFA	✓	×	✓
无 Multimodal	✓	✓	×

表 3: 消融实验条件矩阵 ($2^3 = 8$ 种组合)

各条件的准确度差异 Δ_{acc} 量化了每个模块的信息增益。

29 持续学习收敛分析

连续学习循环的精度趋势估计：

$$\hat{a}_k = \frac{1}{|\mathcal{F}_k|} \sum_{(\bar{p}_i, y_i) \in \mathcal{F}_k} \mathbb{I}[\text{corrected_label}_i = \text{predicted_label}_i] \tag{104}$$

Platt 参数的收敛路径：

$$\begin{bmatrix} A_k \\ B_k \end{bmatrix} = \begin{bmatrix} A_{k-1} \\ B_{k-1} \end{bmatrix} - \eta \cdot \frac{1}{|\mathcal{F}_k|} \sum_i \begin{bmatrix} (p_i - y_i) \cdot \bar{p}_i \\ (p_i - y_i) \end{bmatrix} \tag{105}$$

当 $|\mathbb{E}[p_i - y_i]| < \epsilon$ 时系统达到校准平衡，此时 $\gamma_{\text{cal}} \approx \mathbb{E}[y_i \mid \bar{p}_i]$。

30 退化水平对输出的影响

退化等级	DMA 后端	TFA 后端	预期精度影响
L0 (NORMAL)	Ollama Llama3:8b	MedTsLLM-v1.5	基准
L1 (MINOR)	Ollama + 4-bit quant	MedTsLLM-v1.5	$\approx -2\%$
L2 (PARTIAL)	Ollama Llama3:8b	Heuristic fallback	$\approx -5\%$ —TFA 风险精度降
L3 (SEVERE)	Legacy fallback	Heuristic fallback	$\approx -10\%$ —整体性能降

表 4: 退化等级-精度影响映射

31 系统全面报告 (Full Report)

`get_full_report()` 输出的完整生态系统快照包含：

- **数据集统计**: 样本数、类别分布、训练/测试划分
- **任务统计**: 历史任务数、博弈轮次、近期预测
- **智能体状态**: 10 个智能体的调用次数、故障数、运行时统计
- **实验指标**: 消融 × 4 条件、鲁棒性 × 3 噪声、适应性 × 4 比例、常见/罕见对比
- **退化状态**: 组件状态、退化等级、回退次数
- **持续学习**: 循环次数、缓冲反馈、近期指标趋势

第五部分 公理体系推演——Axiomatic Foundations of HMAE

本部分是本文的核心理论创新。我们从 *HMAE* 的工程实现和数学结构中
逆向归纳出 *8* 条公理，构成本系统的公理化基础。
这些公理不是假设的——每一条都直接来源于前四部分中推导的数学公式。

32 从工程实现到公理体系的逆向归纳

32.1 为什么需要公理化

前四个部分详细描述了 HMAE 的数学公式和物理类比，但它们仍然是**描述性的**（descriptive）——告诉我们系统" 如何运作"。本部分的目标是建立**规范性的**（normative）基础——推导系统" 必须遵循什么原则"。

公理化有四个核心价值：

1. **完备性检验**：公理体系揭示系统设计是否自洽，是否存在逻辑漏洞
2. **可扩展性指导**：新模块的设计必须满足已有公理，否则会破坏系统一致性
3. **性质证明**：从公理出发，可以推导出系统行为的必然性质（定理），而非仅靠实验观察
4. **跨领域迁移**：公理体系抽象掉了医疗领域的具体细节，使得系统架构可以迁移到其他高风险决策领域（金融、法律、航空）

32.2 归纳方法论

公理的提炼遵循以下方法：

1. 从前四部分中识别**不变量**（物理类比表中的第三列）
2. 检查每个不变量的**适用范围**——它是否在所有运行条件下成立
3. 将不变量提升为公理，并明确其**形式化表达**
4. 验证公理之间的**独立性**——每条公理不能从其他公理推导出来

33 八大公理

公理 33.1 (感知完备性——Perception Completeness)**.** *对任意多模态输入 (X_{txt}, X_{img})，存在一个 L2 归一化的融合映射 $\Phi : \mathcal{X}_{txt} \times \mathcal{X}_{img} \to S^{d-1}$，使得对于任何与下游任务相关的信息分量 $\mathcal{I}$，当 $\mathcal{I}$ 在原始信号中可检测时，Φ 的输出保留 $\mathcal{I}$ 的线性可分性。*

即：若 $\exists$ 分类器 f 使 $f(\mathcal{I}(X)) = y$，则 $\exists$ 线性分类器 g 使 $g(\Phi(X)) = y$，且 $\|g\|_{Lip} \leq \frac{1}{\sqrt{d}}$。

来源：此公理来源于感知智能体的交叉注意力融合公式（式 7）。L2 归一化 + 交叉注意力的复合操作构成一个压缩但保信息的映射。$\|g\|_{\text{Lip}} \leq 1/\sqrt{d}$ 的 Lipschitz 约束来源于 $\mathbf{W}_{\text{fusion}}$ 的初始化 $w_{ij} \sim \mathcal{N}(0, 1/\sqrt{d})$——权重矩阵的谱范数期望为 $O(1)$，通过 $1/\sqrt{d}$ 因子控制。

物理意义：这是" 信息不灭" 在有限容量系统中的弱化版本——我们无法保留所有信息（维度从 $\sim 10^5$ 降至 128），但保证保留了所有线性可分的任务相关信息。这类似于量子力学中的**无克隆定理**的逆命题：虽然我们无法完美复制量子态的所有信息，但可以提取对于特定测量（任务）最优的表征。

公理 33.2 (检索不确定性与成本权衡——Retrieval Uncertainty-Cost Trade-off)**.** *对任意查询 q，检索系统的最优策略 (s^*, m^*) 满足：*

$$(s^*, m^*) = \arg\max_{s,m} \left[\lambda \cdot \mathbb{E}[P(correct)] - (1 - \lambda) \cdot C(s, n)\right] \tag{106}$$

且存在信息论下界，具体形式依赖于检索系统的信息率失真函数，此处不展开。其中 $H(Y \mid \cdot)$ 为给定知识状态下的条件熵，$C_{\max}$ 为最大可行成本。

来源：此公理来源于 RAA 的不确定性量化（式 15）和纳什均衡检索策略选择（式 59）。信息论下界将条件熵与检索成本联系起来——降低不确定性的唯一途径是付出检索成本，且存在一个由率失真函数描述的不可逾越的下界。

物理意义：这是**兰道尔原理 (Landauer's principle)** 在信息检索中的类比。兰道尔原理指出：擦除 1 比特信息至少消耗 $kT\ln 2$ 的能量。类似地，我们的下界表明：减少 $H(Y \mid q) - H(Y \mid q, \mathcal{K})$ 的不确定性至少需要付出与检索文档数成比例的计算成本。信息不是免费的——这一热力学约束在 AI 系统中同样成立。

公理 33.3 (决策分布的低温收敛——Low-Temperature Decision Convergence)**.** *设 DMA 的原始得分为 $\mathbf{s} \in \mathbb{R}^{|\mathcal{C}|}$，softmax 温度为 T。则当 $T \to 0^+$ 时，决策分布收敛于决定性输出：*

$$\lim_{T \to 0^+} P(c \mid q) = \mathbb{I}[c = \arg\max_{c'} s_{c'}] \tag{107}$$

且对任意 $\delta > 0$，存在 $T_0 > 0$ 使得当 $T < T_0$ 时：

$$\max_c P(c \mid q) \geq 1 - \delta \tag{108}$$

来源：此公理直接来源于 DMA 的 softmax 公式 ($T = 0.18$)。$T = 0.18$ 是实践中的有限温度近似——它不是无穷小，但足够小以保证 $\max_c P(c) \approx 0.85^+$（实验观察），同时保留概率排序信息。

物理意义：这是**热力学第三定律**在决策理论中的类比——当温度趋于绝对零度时，熵趋于零（系统进入纯态）。在 DMA 中，$T \to 0$ 意味着决策分布的熵趋于零——系统给出完全确定的输出。有限温度 $T = 0.18$ 代表一个" 低温但非绝对零度" 的操作点：系统高度确定但保留了一小部分不确定性（熵 $H \approx 0.2$–0.5 bits），用于后续校准和学习。

公理 33.4 (时序预测的马尔可夫因果性——Temporal Markov Causality)**.** *TFA 的多窗口风险预测 $\mathbf{r} = [r_s, r_m, r_l]^\top$ 满足因果时序约束：*

$$\forall t_1 < t_2 < t_3 : \ r_{short}(t_3) \text{ 在给定} r_{mid}(t_2) \text{ 的条件下与} r_{long}(t_1) \text{ 条件独立} \tag{109}$$

*即风险演化过程构成**非齐次马尔可夫链**：*

$$P(r_{short} \mid r_{mid}, r_{long}) = P(r_{short} \mid r_{mid}) \tag{110}$$

来源：此公理来源于 TFA 多窗口预测的三层结构——$r_{\text{long}} \to r_{\text{mid}} \to r_{\text{short}}$ 的信息流方向隐含了条件独立性。这从式 $r_{\text{mid}} = 0.72 \cdot r_{\text{base}} + 0.28 \cdot \sigma(\cdots)$ 中 r_{base} 只依赖于近期均值、r_{short} 只依赖于当期信号这些结构约束中推导出来。

物理意义：这是**时间之箭（arrow of time）**在风险预测中的体现——长期风险影响中期风险，中期风险影响短期风险，但短期风险不能直接影响长期风险（因果箭头严格向前）。数学上，这确保了使用动态规划（Bellman 方程）进行风险路径优化的可行性。

公理 33.5 (共识收敛——Consensus Convergence)**.** *HMAE 的三层级共识决策过程在有限步内终止，且终止时的决策是在给定信息下的纳什均衡结果：不存在另一种决策同时满足：*

(i) 诊断置信度更高

(ii) 风险预测的假阴性率或假阳性率更低

(iii) 信息获取成本不高于当前

即该决策无法在不降低诊断置信度或不增加成本的情况下进一步降低风险预测的不确定性。

来源：此公理来源于共识智能体的三层级架构和纳什均衡收敛证明（§10、§11）。有限步终止由势博弈的单调收敛性质保证（见 §11.3 的 remark）。纳什均衡性质由势博弈中的最佳响应迭代推导得出。

物理意义：这是**热力学第二定律**在决策系统中的应用——共识过程是一个" 熵减" 过程：初始时各智能体对决策存在分歧（高熵状态），通过三层级投票和博弈迭代，系统自发演化到一个低熵的共识状态，且该状态是纳什均衡的——不存在" 免费的午餐" 可以通过进一步的共识迭代来单方面改善。

公理 33.6 (隐私-效用平衡——Privacy-Utility Equilibrium)**.** 对于任意隐私预算 $\epsilon > 0$，存在噪声标准差 $\sigma_{noise} > 0$ 使得梯度发布满足 (ϵ, δ)-差分隐私，且精度损失与隐私保护满足：

$$\Delta_{acc}(\epsilon) \leq \frac{\kappa}{\epsilon} \cdot \sqrt{\frac{2\log(1.25/\delta)}{d}} \tag{111}$$

其中 κ 为模型 *Lipschitz* 常数，d 为梯度维度。

来源：此公理来源于隐私智能体的高斯机制（§7）。上界 $\Delta_{\text{acc}} \propto 1/(\epsilon\sqrt{d})$ 表明维度 d 提供了" 免费隐私"——高维模型在相同 ϵ 下的精度损失更小。

物理意义：这是**海森堡不确定性原理**在隐私-效用空间中的类比：$\Delta_{\text{acc}} \cdot \epsilon \gtrsim \text{const}$——你无法同时获得极高的精度和极强的隐私保护。精度与隐私构成一对共轭变量，二者的乘积存在一个不可消除的下界。

公理 33.7 (退化安全性——Degradation Safety)**.** 对于任意组件故障组合 $\mathcal{F} \subseteq \mathcal{A}$，退化管理器保证存在可行决策路径：

$$\forall \mathcal{F}, \forall q:\ \exists a \in \mathcal{A}_{decision} \text{ 使得} path(Input, a \mid \mathcal{F}) \neq \emptyset \tag{112}$$

即系统的**安全状态**在任何故障组合下都是可达的。

来源：此公理来源于退化管理器（§18）和通信拓扑（§9）。退化等级的级联设计保证了：即使所有高级组件均故障，系统仍可回退至最基础的规则决策（L3 级别）。

物理意义：这是**控制论中的安全状态可达性 (safe-state reachability)** 在 AI 系统中的形式化——无论哪些组件失效，系统必须始终存在至少一条路径到达一个安全决策。在航空领域，这被称为" 失效-安全 (fail-safe)" 设计；在核工程中，这被称为" 纵深防御 (defense-in-depth)"。

公理 33.8 (持续学习的期望损失递减——Expected Loss Descent)**.** *HMAE* 的持续学习循环保证在凸损失假设下，期望损失单调递减：

$$\mathbb{E}[\mathcal{L}(\Theta_{t+1})] \leq \mathbb{E}[\mathcal{L}(\Theta_t)] - \eta \cdot \|\mathbb{E}[\nabla_\Theta \mathcal{L}]\|_2^2 + \frac{\eta^2}{2} \cdot L \cdot \mathbb{E}[\|\nabla_\Theta \mathcal{L}\|_2^2] \tag{113}$$

其中 $\eta = 0.08$ 为学习率，L 为损失函数的 *Lipschitz* 常数。当 $\eta < 2/L$ 时，期望损失严格递减直至收敛到一阶驻点。

来源：此公理来源于持续学习循环（§19）和 SGD 收敛理论。不等式中的第一项 $-\eta\|\mathbb{E}[\nabla]\|^2$ 是梯度下降的确定性部分（始终减小损失），第二项 $+\frac{\eta^2 L}{2}\mathbb{E}[\|\nabla\|^2]$ 是随机梯度的方差惩罚（噪声使收敛变慢，但不改变下降方向）。

物理意义：这是**最小作用量原理**在学习动力学中的体现——参数更新沿着" 损失景观" 的最陡下降方向移动，系统自发向低损失状态演化。η 控制每一步的步长，L 描述损失曲面的粗糙度。$\eta < 2/L$ 的条件确保了" 步长不足以跳过局部最小值"。

34 从公理到定理

34.1 公理体系的完备性与独立性

完备性声明：上述 8 条公理覆盖了 HMAE 系统的所有关键方面：

- 感知与表征（公理 33.1）
- 信息获取与检索（公理 33.2）
- 决策与推断（公理 33.3）
- 时间与预测（公理 33.4）
- 共识与协调（公理 33.5）
- 隐私与安全（公理 33.6）
- 可靠性与容错（公理 33.7）
- 学习与适应（公理 33.8）

独立性论证：每条公理关注系统的一个正交维度，不存在逻辑推导关系：

- 公理 33.1（感知）不能推导公理 33.4（时序）——表征空间的结构不蕴含时间演化规律
- 公理 33.3（决策）不能推导公理 33.5（共识）——单智能体的决策理论不能推导多智能体的博弈均衡
- 公理 33.6（隐私）不能推导公理 33.7（退化）——隐私保护与故障容错是正交的安全维度
- 公理 33.8（学习）不能推导公理 33.2（检索）——参数更新与信息检索是独立的机制

34.2 可推导的核心定理

定理 34.1 (安全诊断定理——Safe Diagnosis Theorem)**.** *在公理 33.1–33.5 的假设下：当 DMA 置信度低于 $\tau_{conf} = 0.62$ 或 TFA 风险等级为 critical 时，HMAE 系统必然通过第 1 层（FORCE_HITL）或第 2 层（DMA_VETO）升级至人工干预，从而避免在这些条件下出现过度自信型错误。对于高置信度（≥ 0.8）且低风险的情况，系统可能发生错误，但通过公理 33.8 的持续学习和 Platt 校准机制逐步改善。*

证明概要：共识智能体的第 1 层 (FORCE_HITL) 是安全网——任何高危信号（DMA 置信度 < 0.62、验证严重冲突、TFA 风险等级 critical、TFA-诊断冲突）直接触发人工干预，不可被后续层级覆盖。第 2 层 DMA_VETO 是第二道防线——DMA 置信度不足时一票否决。两层防御保证在低置信度或高风险的条件下假阴性率被严格控制。对于高置信度低风险的情况，系统的自主决策受 Platt 校准和持续学习的统计规律支配，存在不可消除的错误概率，但此概率随学习步数增加而递减。□

定理 34.2 (信息获取的边际递减定理——Diminishing Returns of Retrieval)**.** *在公理 33.2 的假设下，每增加一个检索文档的边际信息增益递减：*

$$\frac{\partial}{\partial k} H(Y \mid q, \mathcal{K}_k) < 0, \quad \frac{\partial^2}{\partial k^2} H(Y \mid q, \mathcal{K}_k) > 0 \tag{114}$$

即条件熵随检索文档数 k 递减，但递减速率越来越慢（凸函数）。

证明概要：检索文档按相似度降序排列。第 k 个文档的相关性 s_k 随 k 递减（至少不增），其对条件熵的贡献正比于 s_k。因此 $\partial H/\partial k \propto -s_k$（负值递减）且 $\partial^2 H/\partial k^2 \propto s_k - s_{k+1} \geq 0$。□

定理 34.3 (容错完备性定理——Fault-Tolerance Completeness)**.** *在公理 33.7 的假设下，HMAE 在任何单点故障（任意一个智能体失效）下保持功能完整；在任何双点故障下保持降级功能；仅在三点及以上故障时可能完全不可用。*

证明概要：退化等级的 $L = 0, 1, 2, 3$ 定义中，$L = 2$ (PARTIAL) 对应 unavailable ≥ 1——即一个组件不可用时系统仍在 PARTIAL 级别（功能降级但可用）。$L = 3$ (SEVERE) 对应 unavailable ≥ 3——需要三个组件同时不可用才进入严重退化。因此双点故障时系统最多处于 PARTIAL 级别。□

35 公理体系在非医疗领域的可迁移性

HMAE 的公理体系虽然源自医疗 AI，但其抽象层次足够高，可以直接迁移到其他高风险决策领域：

公理	医疗领域体现	可迁移领域
感知完备性 (公理 1)	文本 + 影像融合	自动驾驶（摄像头 + 激光雷达）
检索不确定性 (公理 2)	医学文献检索	法律判例检索、金融研报检索
低温收敛 (公理 3)	诊断决策	信贷审批、欺诈检测
时序因果性 (公理 4)	病情风险预测	设备剩余寿命预测、市场风险预测
共识收敛 (公理 5)	多专家会诊	多方风控评审、AI 伦理委员会
隐私均衡 (公理 6)	患者数据保护	金融交易隐私、企业机密保护
退化安全 (公理 7)	系统容错	航空飞控、核电站控制
持续学习 (公理 8)	在线校准	推荐系统、自适应控制

表 5: 公理体系的跨领域可迁移性

36 公理体系的方法论意义：从”工程直觉”到”形式化保证”

HMAE 公理体系的建立标志着系统设计从**经验工程阶段**进入**形式化工程阶段**：

1. **之前（经验工程）**：系统设计依赖工程师的直觉和经验，”这个阈值设为 0.62 是因为效果好”、”加噪声是因为要保护隐私”
2. **之后（形式化工程）**：每个设计选择都有公理级的形式化理由。”$\tau_{\text{conf}} = 0.62$ 是公理 3（低温收敛）和公理 5（共识收敛）的交叉约束下的最优解”、”$\sigma_{\text{noise}} = 0.015$ 是公理 6（隐私均衡）在 ϵ 预算约束下的解”

这一转变的核心价值不在于" 找到了对的参数"（参数可能随数据变化），而在于**建立了参数选择的逻辑链条**——任何参数的调整都可以追溯到一个或多个公理，从而可以进行形式化的敏感性分析和安全性验证。

附录

A. 关键常数表

符号	值	含义
d	128	嵌入维度
$k_{\max}$	2400	TF-IDF 最大特征数
τ_{conf} (confidence_threshold)	0.62	DMA 置信度阈值
τ_{ret} (retrieval_relevance_threshold)	0.24	检索相关性阈值
λ (cost_lambda)	0.72	精度-成本权衡
$N_{\max}$ (nash_max_rounds)	6	Nash 均衡最大迭代轮数
T (dma_softmax_temperature)	0.18	DMA Softmax 温度
T_g (retrieval_query_softmax_temperature)	0.35	RAA 门控 Softmax 温度
τ_{dup} (fusion_duplicate_hamming_threshold)	4	文档去重汉明距离
τ_{conflict} (fusion_conflict_hamming_threshold)	26	冲突检测汉明距离
τ_U (query_uncertainty_threshold)	0.58	查询不确定性阈值
σ_{noise} (secure_gradient_noise_std)	0.015	差分隐私噪声标准差
η (lora_learning_rate)	0.08	文档权重学习率
η_g (gradient_margin_shift_rate)	0.02	检索裕度偏移率
τ_{risk} (high_risk_tfa_threshold)	0.65	TFA 高风险阈值
τ_{timeout} (agent_timeout_seconds)	120s	智能体超时
$\tau_{\text{ver_age}}$ (verification_max_age_days)	365	文档时效上限
w_{DMA}	2	DMA 共识投票权重
w_{TFA}	1	TFA 共识投票权重
w_{Ver}	1	验证投票权重
pass_threshold	3	共识通过所需总权重
$n_{\min}$ (continuous_learning_min_feedback)	10	持续学习触发反馈数

表 6: 系统关键常数

B. 模块映射表

章节	模块/类名	核心数学操作

§1	MultimodalPerceptionAgent	交叉注意力融合 (式 7)
§2	RetrievalAugmentedAgent	TF-IDF + FAISS + 不确定性量化
§3	DecisionMakingAgent	多源得分融合 + Platt 校准 + Llama3
§4	TemporalForeseeingAgent	TCN/EMA/Trans + 门控融合 + RevIN + Reprogramming
§5	KnowledgeFusionAgent	SimHash + 汉明去重 + 冲突检测
§6	KnowledgeVerificationAgent	多源事实评分 + 时效性检查
§7	KnowledgeDistillationEngine	Fréchet 均值 (加权球面平均)
§8	HumanInTheLoopManager	干预判定逻辑 + 三型错误分类
§9	PrivacySecurityAgent	高斯差分隐私 + XOR 流加密
§10	ConsensusModule	三层级投票矩阵
§11	博弈论检索	纳什均衡最佳响应迭代
§12	OnlineKnowledgeBaseManager	增量 KB 更新 + FAISS 重建
§13	MedTsLLMAdapter	Cross-Attention Reprogramming + BioBERT

C. 公理-定理-参数依赖图

公理	可推导定理	约束的关键参数
公理 1 (感知完备性)	安全诊断定理	$d = 128$, $\mathbf{W}_{\text{fusion}}$ 初始化
公理 2 (检索不确定性)	边际递减定理	$\lambda = 0.72$, $\tau_U = 0.58$, $k_{\max} = 2400$
公理 3 (低温收敛)	安全诊断定理	$T = 0.18$, Platt (A, B)
公理 4 (时序因果性)	安全诊断定理	$T = 72$, $\alpha = 0.18$, 三窗口权重
公理 5 (共识收敛)	安全诊断定理 + 容错完备性	$\tau_{\text{conf}} = 0.62$, $N_{\max} = 6$, 权重 $[2, 1, 1]$
公理 6 (隐私均衡)	—	$\sigma_{\text{noise}} = 0.015$
公理 7 (退化安全)	容错完备性定理	$\tau_{\text{timeout}} = 120s$, $L \in \{0, 1, 2, 3\}$
公理 8 (期望损失递减)	—	$\eta = 0.08$, $n_{\min} = 10$

表 8: 公理-定理-参数依赖关系